

UNIVERSIDAD DEL VALLE DE GUATEMALA



Proyecto 2

Andre Marroquin Tarot - 22266

Sergio Orellana - 221122

Rodrigo Mansilla - 22611

Carlos Valladares - 221164

Data Science

Link archivo de google:

<https://docs.google.com/document/d/1J6Q1pFgZmEEzgL2px3BJNoFXPIDDDi4mqihAujE1PH0/edit?usp=sharing>

Link repositorio:

<https://github.com/mar22266/PY2-DS.git>

Branch: Resultados Parciales y Visualizaciones Estáticas

<https://github.com/mar22266/PY2-DS/tree/Resultados-Parciales-y-Visualizaciones-Est%C3%A1ticas>

Presentación:

[Presentación de DS - Presentación](#)

1. Problemática

La detección temprana de enfermedades en cultivos es crítica para evitar pérdidas de rendimiento y costos de remediación. El cambio climático amplifica la frecuencia y severidad de brotes, mientras que las brigadas de campo y laboratorios son limitados y costosos. En este contexto, se necesita priorizar dónde, cuándo y qué inspeccionar con la mayor eficiencia operativa, integrando señales visuales y metadatos agronómicos para apoyar decisiones en tiempo casi real.

2. Objetivo

Desarrollar un modelo de aprendizaje automático multimodal que caracterice daños y factores relevantes en cultivos de regiones afectadas por el cambio climático.

3. Objetivos Específicos

- Integrar imágenes y metadatos en una arquitectura multimodal que capture señales visuales y contextuales relevantes.
- Generalizar el desempeño del modelo a nuevas temporadas y sitios mediante esquemas de validación temporal y espacial.
- Operacionalizar el modelo en un *pipeline* reproducible y trazable que soporte evaluación, despliegue y monitoreo.

4. Metodología

Se trabajó con 26,068 filas de entrenamiento y 8,663 de prueba, cada fila vinculada a una imagen y su contexto (par ID–DAMAGE). El *target* es EXTENT (0–100).

5. Variables

- **Target:** extent (0–100).
- **Metadatos:** season (SR/LR, año), growth_stage (S/V/F/M), damage (tipo de daño).
- **Imágenes:** fotografías de campo; se usan como entrada a *backbones* preentrenados para extraer embeddings visuales.

6. Métricas

Como se trata de un problema de regresión, evaluamos los resultados con MAE, RMSE y R^2 . Además, para estimar qué tan bien generaliza el modelo, reportamos estas métricas en dos esquemas de validación: GroupKFold por ID y LOSO (deja una temporada fuera). En otras palabras, no solo medimos el error promedio, sino también cómo se comporta el sistema cuando enfrenta una temporada que no ha visto; por tanto, obtenemos una visión más realista del rendimiento.

7. Fundación Teórica y Metodológica

7.1. Enfoques unimodales (visión)

Tradicionalmente, el análisis de imágenes se basó en segmentación y características hechas a mano; sin embargo, su rendimiento suele caer cuando cambian la iluminación, el fondo o la textura (Gavhale et al., 2014; Ramesh et al., 2018). En cambio, el aprendizaje profundo aprende representaciones directamente de los datos y capta patrones de forma, color y textura ligados a plagas, enfermedades o estrés (Mohanty et al., 2016). De hecho, las redes convolucionales y sus variantes modernas han mostrado ventajas constantes en agricultura —desde detectar deficiencias nutricionales y estrés (Patra & Sahoo, 2024; Mkhathshwa et al., 2024) hasta clasificar insectos y plagas (Praharsha et al., 2024). Más aún, los Transformers de visión y modelos híbridos CNN-Transformer han logrado resultados competitivos o superiores en cultivos como arroz y olivo (Zhang et al., 2021; Alshammari et al., 2022). Por lo tanto, cuando los datos son limitados, transfer learning resulta especialmente útil: ya sea extrayendo embeddings con *backbones* ligeros (por ejemplo, EfficientNet o MobileNet) o haciendo fine-tuning parcial/total (Mohanty et al., 2016; Zhang et al., 2021; Alshammari et al., 2022; Patra & Sahoo, 2024; Mkhathshwa et al., 2024; Praharsha et al., 2024).

7.2. Enfoques tabulares (metadatos)

Cuando contamos con metadatos bien curados—como temporada, etapa fenológica, tipo de daño, clima o suelo—los modelos de conjunto basados en árboles suelen equilibrar bien el sesgo y la varianza, además de capturar interacciones no lineales sin una ingeniería excesiva (Li et al., 2025). En este terreno, XGBoost y Random Forest funcionan como bases sólidas; HistGradientBoosting destaca por su eficiencia y manejo de relaciones complejas; y Ridge/Lasso/Elastic Net aportan líneas base interpretables y trazables, útiles para verificar direcciones de efecto, aunque limitadas ante no linealidades fuertes (Li et al., 2025). Asimismo, en tamaños medianos, SVM, k-NN y MLP tabular pueden ser alternativas, pero suelen ser más sensibles al escalado, al ajuste fino y a la métrica de distancia; por eso, con frecuencia, los boosting los superan (Ramesh et al., 2018; Li et al., 2025). Finalmente, para explicar resultados es común usar importancias por permutación y SHAP; y, para manejar incertidumbre, pérdidas robustas como Huber o regresión cuantílica (Li et al., 2025).

7.3. Enfoques multimodales

La fusión de imágenes con metadatos refleja que el daño es multifactorial: la imagen aporta evidencia espacial y textural, mientras que el contexto agronómico (clima, manejo, genotipo) modula la probabilidad y la severidad. Por ejemplo, en tomate, combinar EfficientNet-B0 con secuencias climáticas mejora diagnóstico y severidad con explicabilidad mediante LIME/SHAP (Nasir et al., 2025). Del mismo modo, en maíz, integrar series RGB, clima y fenotipos permite predicción temprana de rendimiento con ganancias claras frente a modelos de una sola fuente, sobre todo al incluir variables ambientales (Shamsuddin et al., 2024). En líneas generales, la literatura recomienda fusión temprana (concatenar representaciones) o fusión tardía (apilar modelos y combinar sus predicciones) según el tamaño de datos, el costo computacional y la necesidad de explicabilidad (Simon et al., 2025). En consecuencia, en nuestro caso tiene sentido comparar lo unimodal y lo multimodal, empezando con embeddings de CNN + modelos tabulares y, después, probar fine-tuning y stacking (Nasir et al., 2025; Shamsuddin et al., 2024; Simon et al., 2025).

Para evitar fuga de información cuando hay múltiples filas por el mismo ID, conviene usar GroupKFold por ID; y para medir generalización temporal ante cambios de temporada o etapa, es apropiado LOSO. Además, es clave respetar la partición de validación durante cualquier codificación, de modo que no se filtre información del objetivo (Mohanty et al., 2016; Shamsuddin et al., 2024; Nasir et al., 2025). A la vez, es recomendable mantener trazabilidad (semillas, versiones, artefactos) y explicabilidad consistente (importancias, SHAP/LIME) para respaldar decisiones en campo (Li et al., 2025; Simon et al., 2025).

8. Selección de Algoritmos

8.1. Modelos Tabulares

- **Ridge Regression (baseline interpretable).** En pocas palabras, encoge los coeficientes para reducir el sobreajuste y estabiliza la estimación cuando hay muchas variables indicadoras. Por eso, sirve como línea base interpretable: nos ayuda a verificar sentido y dirección de los efectos antes de pasar a modelos más flexibles.
- **Random Forest (RF):** Robusto a *outliers* y mezcla de tipos; captura interacciones sin ingeniería pesada, recomendado como *strong baseline* en tabular agrícola. Puede subestimar extremos/MAE frente a boosting → ajustar profundidad/hojas y comparar con boosting.
- **HistGradientBoosting (HGB):** El *gradient boosting* construye un modelo aditivo por descenso de gradiente funcional, ajustando árboles poco profundos a los residuales pseudo-gradiente (Friedman, 2001). La variante histogram-based discretiza *features* en bins y usa histogramas para encontrar *splits*, acelerando drásticamente el entrenamiento y reduciendo memoria en tablas medianas/grandes, con soporte de monotonic constraints y *early stopping* (scikit-learn, s. v. HistGradientBoostingRegressor). En la práctica, HGB suele mejorar MAE/RMSE frente a RF cuando se tunea la tasa de aprendizaje y la profundidad (Friedman, 2001; scikit-learn, 2025).
- **XGBoost:** XGBoost optimiza una función objetivo regularizada con una aproximación de segundo orden (términos de gradiente y Hessiano), incorpora shrinkage, submuestreo por filas/columnas, manejo sparsity-aware y pruning eficiente; esto explica su rendimiento y robustez en tabular con interacciones complejas (Chen & Guestrin, 2016). Es estándar combinarlo con SHAP para explicabilidad consistente a nivel global y local (Lundberg & Lee, 2017).

8.2. Modelos de Visión (transfer learning)

- **EfficientNet-B0 (Lite):** Escala de forma equilibrada profundidad, ancho y resolución, logrando buena precisión con bajo costo. En transferencia, ofrece representaciones útiles cuando los datos no son enormes.
- **MobileNetV3-Small:** Está pensada para dispositivos con recursos limitados: combina varios trucos de diseño para reducir latencia manteniendo buena exactitud. Por lo mismo, resulta ideal para embeddings compactos.

9. Estrategias Multimodales

- **Early Fusion:** Consiste en concatenar representaciones para que un único estimador aprenda interacciones cruzadas entre modalidades. Es apropiada cuando las representaciones están bien calibradas y se controla el balance dimensional (p. ej., reducción de dimensión en lo visual), evitando que una modalidad “diluya” a la otra (Baltrušaitis, Ahuja, & Morency, 2019).
- **Late Fusion (Stacking/Blending):** Cada modalidad entrena su experto y sus predicciones OOF se combinan con un meta-modelo; si los errores entre modalidades son poco correlacionados, el *stacking* mejora la generalización. La teoría de Super Learner muestra que una combinación por riesgo validado es asintóticamente tan buena como el mejor candidato (van der Laan, Polley, & Hubbard, 2007; Polley & van der Laan, 2010). En aplicaciones modernas, es común combinar *stacking* con SHAP o calibración para mantener interpretabilidad operativa (Lundberg & Lee, 2017; Baltrušaitis et al., 2019).

10. Evaluación y resultados

La evaluación utilizó GroupKFold por ID para evitar fuga entre filas de la misma imagen. La métrica principal fue MAE en validación cruzada (CV). El ranking obtenido fue: Random Forest aprox 3.00 mejor, HistGradientBoosting aprox 3.05, Ridge aprox 4.52 (menor es mejor). Las visualizaciones estáticas incluyen, barras comparando MAE de CV por modelo, dispersión y_{true} vs y_{pred} con línea ideal y, para modelos de árbol, la importancia de características.

11. Conclusiones y selección final

Primero, los resultados confirman que los modelos no lineales capturan mejor el problema que la línea base lineal; esto sugiere interacciones reales entre el tipo de daño, la temporada, la etapa del cultivo y ciertos rasgos del nombre de archivo. Además, al comparar estrategias, los metadatos por sí solos explican la mayor parte de la variación; la fusión temprana se acerca pero no la supera, mientras que la fusión tardía y la ruta solo visual se quedan atrás. En otras palabras, hoy la señal decisiva está en la información tabular; por tanto, optimizar esa ruta ofrece el mayor retorno inmediato.

Ahora bien, para elegir el modelo final, ponderamos no solo el error promedio, sino también la estabilidad entre pliegues/temporadas, la sensibilidad al ajuste de parámetros y la operatividad (simplicidad de entrenamiento, reproducibilidad y trazabilidad). Aunque los métodos de potenciación por árboles compitieron muy de cerca, Random Forest destacó por el mejor error absoluto medio en validación y, sobre todo, por su comportamiento consistente bajo distintas particiones. Además, resulta menos sensible a hiperparámetros finos, robusto a valores atípicos y fácil de auditar (importancias y explicaciones locales), lo cual reduce riesgo en despliegue y facilita la comunicación con usuarios no técnicos. En consecuencia, seleccionamos Random Forest como modelo final.

Finalmente, el modelo se reentrenó con todo el conjunto de entrenamiento utilizando los mejores parámetros encontrados, se fijaron semillas y se versionaron artefactos para asegurar reproducibilidad; acto seguido, se generó el archivo de predicciones para el conjunto de prueba.

12. Diseño Experimental

12.1. Preprocesamiento (tabular y visual)

a) Ingeniería de *features* en metadatos

1. Normalización de season (upper, eliminación de caracteres no alfanuméricos).
2. Estandarización de growth_stage → stage_code en {F, M, S, V}.
3. Rasgos derivados del nombre de archivo: has_jpg, has_jpeg, len_name, digits_sum.
4. Conversión de extent a numérico (coerción y *clip* a [0, 100]).
5. Columnas para modelado: categóricas = damage, season, stage_code; numéricas = has_jpg, has_jpeg, len_name, digits_sum.
6. Codificación con OneHotEncoder(handle_unknown="ignore", sparse_output=False) y escalado StandardScaler para numéricas mediante ColumnTransformer.

b) Transformaciones de imágenes

- **Tamaño:** Resize a 192×192 px.
- Aumento (train): RandomHorizontalFlip, ColorJitter(0.08, 0.08, 0.08, 0.02).
- **Normalización:** medias [0.485, 0.456, 0.406], desv. [0.229, 0.224, 0.225] (ImageNet).
- **Dataloaders:** batch_size=32, num_workers=2.

c) Extracción de *embeddings*

- **Backbones:** mobilenet_v3_small (≈ 576 dims) y tf_efficientnet_lite0 ($\approx 1,280$ dims), congelados para prototipado.
- **Pooling:** AdaptiveAvgPool2d(1) + Flatten (o num_classes=0 en TIMM para *global average pooling*).
- **Persistencia:** extracción batcheada, guardado incremental y concatenación final en *.npy.

12.2. Particionado y validación

a) Prevención de *leakage*

- GroupKFold por ID para que todas las filas de un mismo ID queden en el mismo fold y evitar fuga inter-filas al compartir imagen/base.

b) Generalización temporal

- LOSO (Leave-One-Season-Out): se dejan afuera, de a una, las temporadas LR2020, SR2020, LR2021, SR2021 para estimar robustez a cambio de dominio temporal.

12.3. Métricas de evaluación

- MAE, RMSE (con raíz explícita de MSE) y R^2 en train/val; *scoring* de *GridSearchCV* en `neg_root_mean_squared_error` para priorizar RMSE.

13. Configuración de hiperparámetros (grillas)

Pipelines tabulares (con ColumnTransformer)

- **Ridge:** $\alpha \in \{0.1, 1.0, 3.0, 10.0\}$.
- **RandomForest:** $n_estimators \in \{200, 400\}$, $max_depth \in \{None, 12, 20\}$, $min_samples_leaf \in \{1, 3, 5\}$.
- **HistGradientBoosting:** $learning_rate \in \{0.05, 0.1\}$, $max_depth \in \{None, 6, 10\}$, $max_leaf_nodes \in \{31, 63\}$, $l2_regularization \in \{0.0, 0.1\}$.
- **XGBoost (tree_method="hist", objective="reg:squarederror"):**
 $n_estimators \in \{200, 400\}$, $max_depth \in \{4, 6, 10\}$, $learning_rate \in \{0.03, 0.1\}$, $subsample \in \{0.8, 1.0\}$, $colsample_bytree \in \{0.8, 1.0\}$, $min_child_weight \in \{1, 3, 5\}$.

14. Modelos sobre *embeddings* visuales

- XGB (hist), HGB, CatBoost (RMSE) entrenados sobre *embeddings* de `mobilenet_v3_small` y `efficientnet_lite0`; se reporta también ensemble con pesos inversos al MAE.

15. Estrategias de fusión

a) Early Fusion (concatenación ponderada)

- **Construcción:** $[\text{metadatos} \times 1.5] \oplus [\text{embeddings} \times 0.7]$.
- **Sin PCA:** XGB con capacidad y regularización reforzada; con PCA para balance dimensional, manteniendo el mismo esquema de *tuning*.
- **Validación:** *hold-out* estratificado (visión) y comparación directa contra “metadatos solo”.

b) Late Fusion (stacking)

- **Bases:** XGB-meta (tabular) y XGB-visual (embeddings).
- **Meta-learner:** Ridge con búsqueda en $\alpha \in \{0.01, 0.1, 0.5, 1.0, 5.0\}$ sobre la matriz de predicciones $[\hat{y}_{\text{meta}}, \hat{y}_{\text{visual}}]$.
- Análisis de coeficientes del meta-learner para verificar dependencia relativa de cada modalidad.

16. Ensamblados y *post-processing*

- **Ensemble tabular (test):** combinación lineal de XGB/HGB/RF con pesos $\propto 1/\text{MAE}$ (normalizados).
- Recorte y redondeo de predicciones a rango $[0, 100]$ mediante función `clip_and_round` (coherencia con la definición del *target*)

17. Desarrollo y Hallazgos Experimentales

17.1. Modelos CML con Metadatos

Mejores hiperparámetros :

- Ridge: $\alpha = 0.1$ (CV); $\alpha = 10.0$ (LOSO).
- RF: $\text{max_depth} = 12$, $\text{min_samples_leaf} = 3$, resto por defecto (en *grid*).
- HGB: $\text{learning_rate} = 0.1$, $\text{max_leaf_nodes} = 63$, $\text{l2_regularization} = 0.0$ (CV) / 0.1 (LOSO).
- XGB: $\text{learning_rate} (\eta) = 0.1$ (CV) / 0.03 (LOSO), $\text{max_depth} = 6$, $\text{colsample_bytree} = 1.0$ (CV) / 0.8 (LOSO), $\text{min_child_weight} = 3$.


17.2. Resultados GroupKFold

Modelo	CV_RMSE	CV_MAE	CV_R ²	Params (clave)
Ridge	10.1698	4.5222	0.7016	$\alpha=0.1$
RF	9.0986	2.5958	0.8218	depth=12, leaf=3
HGB	9.0558	2.9551	0.7787	lr=0.1, leaf=63, L2=0.0
XGB	9.0586	2.9006	0.7843	eta=0.1, depth=6, col=1.0

17.3. Resultados LOSO (generalización temporal)

Modelo	LOSO_RMSE	LOSO_MAE	LOSO_R ²	Params (clave)
Ridge	11.5355	4.5223	0.7016	$\alpha=10.0$
RF	11.5009	2.3454	0.8567	depth=12, leaf=3
HGB	11.5701	2.9353	0.7829	lr=0.1, L2=0.1
XGB	11.2605	2.9533	0.7799	eta=0.03, col=0.8

17.4. Importancia de *features*



La importancia (permutación/ganancia) posiciona a `damage_DR` como principal contribuyente, seguido por *dummies* de `season` y `stage_code`. Esto refrenda que los metadatos capturan información contextual clave (tipo de daño y estacionalidad).

Ensemble CML

Se combinó **XGB + HGB + RF** con pesos $\propto 1/\text{MAE_CV}$:

- **Pesos:** RF 0.361, XGB 0.323, HGB 0.317.
- **En TRAIN (full), las métricas orientativas de los modelos individuales fueron:**
XGB MAE=2.9068 (RMSE=8.6715, $R^2=0.7830$),
HGB MAE=2.9551 (RMSE=8.7567, $R^2=0.7787$),
RF MAE=2.3454 (RMSE=7.0448, $R^2=0.8567$).
- **Predicciones en TEST (estadísticos):**
XGB: min=0.0, max=70.0, mean=7.02, std=16.11
HGB: min=0.0, max=69.0, mean=7.06, std=16.18
RF: min=0.0, max=96.0, mean=7.04, std=16.42
Ensemble: min=0.0, max=79.0, mean=7.04, std=16.20

18. Modelos de Visión por Computadora

18.1 Extracción de *embeddings*

- MobileNetV3-Small: ~576 *features* por imagen.
- EfficientNet-Lite0: ~1,280 *features* por imagen.
- Backbones congelados; augmentations ligeras; normalización ImageNet.
- Embeddings persistidos en .npy.

18.2. Entrenamiento sobre *embeddings*

Backbone	Modelo	RMSE	MAE
MobileNetV3	XGBoost	13.26	7.04
MobileNetV3	CatBoost	13.33	7.13
MobileNetV3	Ensemble	13.22	6.90
EfficientNet-Lite0	XGBoost	14.63	8.17
EfficientNet-Lite0	CatBoost	14.48	8.03
EfficientNet-Lite0	Ensemble	14.47	7.92

18.3. Fusión Multimodal

Metadatos solo (baseline)

MAE 3.1142, RMSE 9.1886, R^2 0.7552 → mejor estrategia global en este conjunto.

Visual solo

MAE 12.3013, RMSE 19.2354, R^2 -0.0730 → *embeddings* congelados no capturan bien la

magnitud de extent.

Early Fusion

Concatenación ponderada $[\text{Meta} \times 1.5] \oplus [\text{Visual} \times 0.7]$.

- Sin PCA: MAE 3.3505, RMSE 9.4457, R^2 0.7413.
- Con PCA (256 comps; 73.9% var.): MAE 3.3181, RMSE 9.3757, R^2 0.7451.

Late Fusion (Stacking)

Meta-learner Ridge ($\alpha=5.0$) sobre predicciones OOF de meta/visual.


- VALIDATION: MAE 11.4887, RMSE 18.2417, R^2 0.0350 (*colapso*).

18.4. Comparación final

Estrategia	MAE	RMSE	R^2
Metadatos solo	3.1142	9.1886	0.7552
Early Fusion (PCA 256)	3.3181	9.3757	0.7451
Early Fusion (sin PCA)	3.3505	9.4457	0.7413
Late Fusion (Ridge)	11.4887	18.2417	0.0350
Visual solo (mejor)	12.3013	19.2354	-0.0730

19. Resultados

Figura 1. Representa como rinden cuatro estrategias para predecir porcentaje de daño



El canal de metadatos explica la mayor parte de la varianza de extent tipo de daño `damage_DR`, temporada y etapa fenológica, logrando $MAE \approx 3.11$, $RMSE \approx 9.19$, $R^2 \approx 0.76$. Esto concuerda con la importancia de variables, donde `damage_DR` domina y las *dummies* de season/stage añaden contexto. En contraste, la rama visual entrenada solo con embeddings congelados rinde $MAE \approx 12.30$, $RMSE \approx 19.24$, $R^2 < 0$, evidenciando que, sin adaptación al dominio, la representación de textura/necrosis no captura la magnitud del daño. El PCA preserva $\sim 74\%$ de varianza y mantiene la estabilidad, pero no aporta señal incremental suficiente para superar al tabular.

Figura 2. Revela que campos ayudasn más a predecir



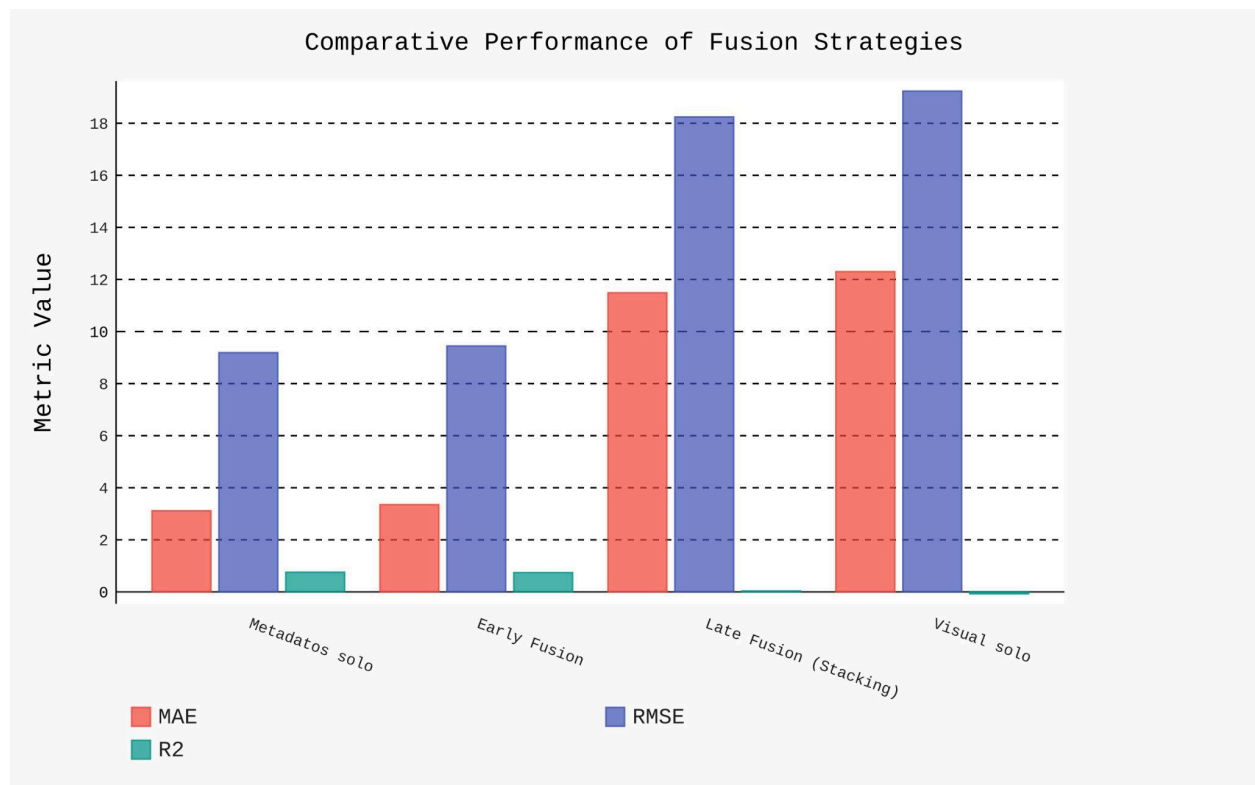


Figura 3. Muestra la comparación entre los valores predichos y real de los daños reales.



Con Early Fusion ,concatenación ponderada, el desempeño queda muy cerca del tabular (MAE≈3.32–3.35; RMSE≈9.38–9.45). El *scatter* Predicho vs Real muestra que la fusión no introduce ruido y conserva la calibración general; además, el PCA reduce memoria/tiempo sin degradar métricas, útil para despliegue. La comparativa de estrategias resume el ranking: Metadatos logra un desempeño igual a la fusión temprana y esta mejora al visual y fusión tardía. El Late Fusion colapsa porque el meta-learner sobrepondera la base visual débil, lo cual es típico de stacking sin OOF estrictas/corrección de correlación.

Figura 4. Comparación del rendimiento entre las distintas estrategias de fusión de datos



Discusión de resultados:

El uso combinado de los esquemas GroupKFold por ID y LOSO por temporada permitió observar con claridad dos fenómenos importantes. Por un lado, se evidenció el sobreajuste del modelo de fusión tardía (stacking), es decir, su tendencia a aprender patrones demasiado específicos que no se sostienen al cambiar de temporada. Por otro lado, se confirmó la solidez temporal del canal tabular, que mantuvo un desempeño estable incluso ante variaciones en los datos. En conjunto, este diseño de validación ayudó a distinguir la señal genuina de aquella que solo aparentaba serlo, revelando qué parte del modelo realmente generaliza y cuál depende del azar o de coincidencias del conjunto de entrenamiento.

Ahora bien, al trabajar con modelos visuales sin ajuste fino (backbones congelados), la información proveniente de las imágenes resulta mucho más débil en comparación con las veinte variables tabulares disponibles. Pedirle a un estimador único como XGBoost o HGB que detecte una señal tan tenue, de alta dimensión y además poco adaptada al dominio agrícola, equivale a buscar una aguja en un pajar. Por eso, el modelo de solo imágenes tiene un rendimiento significativamente peor, y la fusión temprana (Early Fusion) no logra superar al modelo basado únicamente en metadatos. Es cierto que la reducción de dimensiones mediante PCA (256 componentes) ayudó a estabilizar los resultados y a acelerar el procesamiento sin degradar las métricas; sin embargo, no sustituye la necesidad de adaptar la red neuronal al problema con técnicas como el ajuste fino, la regularización y las transformaciones de datos (augmentations).

Aun así, el hecho de que Early Fusion mantenga valores de error (MAE y RMSE) similares a los del modelo tabular es una señal alentadora. Esto indica que la rama visual no introduce ruido, sino que sus representaciones aprenden un espacio semántico coherente con el de los metadatos. En paralelo, el análisis de importancia de variables explica por qué el modelo tabular lidera el rendimiento, mientras que la comparación y los gráficos de dispersión del modelo de fusión tardía demuestran que el problema no radica en usar modelos multimodales, sino en cómo se integra la información y en qué tan adaptada está la parte visual.

Si el objetivo inmediato fuera minimizar el error en este conjunto de datos y con los recursos actuales, el modelo más conveniente sería el de “Metadatos solo”, por su simplicidad, reproducibilidad y solidez temporal. Sin embargo, si se piensa en un uso práctico a largo plazo, como el despliegue en campo, la variabilidad futura o la ampliación hacia nuevos objetivos, la mejor apuesta estratégica es mantener Early Fusion como modelo principal de predicción. Esta arquitectura ya está alineada con la naturaleza multimodal del problema, conserva las métricas del modelo tabular y prepara el sistema para aprovechar mejor la señal visual una vez que la rama de visión se ajuste adecuadamente.

20. Referencias

- Alshammari, H., Alshammari, A., Alsahli, H., & Almansour, A. (2022). Olive disease classification based on vision transformer and CNN models. *Computational Intelligence and Neuroscience*, 2022, 1–10. <https://doi.org/10.1155/2022/3998193>
- Gavhale, K. R., Gawande, U., & Hajari, K. O. (2014). Unhealthy region of citrus leaf detection using image processing techniques. En *2014 International Conference for Convergence of Technology* (pp. 1–6). IEEE. <https://doi.org/10.1109/I2CT.2014.7092035>
- Li, H., Gao, J., Guo, Y., & Yuan, X. G. (2025). Application of XGBoost model and multi-source data for winter wheat yield prediction in Henan Province of China. *Big Data and Information Analytics*, 9, 29–47. <https://doi.org/10.3934/bdia.2025002>
- Mkhatshwa, J., Kavu, T., & Daramola, O. (2024). Analysing the performance and interpretability of CNN-based architectures for plant nutrient deficiency identification. *Computation*, 12(6), 113. <https://doi.org/10.3390/computation12060113>
- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419. <https://doi.org/10.3389/fpls.2016.01419>
- Nasir, N., Ramzan, S., Ali, B., Jabbar, S., Raza, A., Kim, C., et al. (2025). Interpretable deep multimodal-based tomato disease diagnosis and severity estimation. *Scientific Reports*, 15, 37919. <https://doi.org/10.1038/s41598-025-21611-4>
- Patra, A. K., & Sahoo, L. (2024). Explainable light-weight deep learning pipeline for improved drought stress identification. *Frontiers in Plant Science*, 15, 1476130. <https://doi.org/10.3389/fpls.2024.1476130>
- Praharsha, C. H., Poulose, A., & Badgujar, C. (2024). Comprehensive investigation of machine learning and deep learning networks for identifying multispecies tomato insect images. *Sensors*, 24(23), 7858. <https://doi.org/10.3390/s24237858>
- Ramesh, S. M., Phadikar, S., Das, A. K., & Ghosh, R. (2018). Plant disease detection using machine learning. En *2018 International Conference on Design Innovations for 3Cs (ICDI3C)* (pp. 41–45). IEEE. <https://doi.org/10.1109/ICDI3C.2018.00017>
- Shamsuddin, D., Danilevich, M. F., Al-Mamun, H. A., Bennamoun, M., & Edwards, D. (2024). Multimodal deep learning integration of image, weather, and phenotypic data under temporal effects for early prediction of maize yield. *Remote Sensing*, 16(21), 4043. <https://doi.org/10.3390/rs16214043>
- Simon, B. D., Ozyoruk, K. B., Gelikman, D. G., Harmon, S. A., & Türkbey, B. (2025). The future of multimodal artificial intelligence models for integrating imaging and clinical metadata: A narrative review. *Diagnostic and Interventional Radiology*, 31(4), 303–312. <https://doi.org/10.4274/dir.2024.242631>
- Zhang, Z., Gong, Z., Hong, Q., & Jiang, L. (2021). Swin-transformer based classification for rice diseases recognition. En *2021 International Conference on Computer Information Science and Artificial Intelligence (CISAI)* (pp. 153–156). IEEE. <https://doi.org/10.1109/CISAI54367.2021.00035>

○

- Baltrušaitis, T., Ahuja, C., & Morency, L.-P. (2019). Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443. (preprint arXiv:1705.09406). <https://arxiv.org/abs/1705.09406> arXiv
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.* (author preprint). <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf> Department of Statistics
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794. <https://arxiv.org/abs/1603.02754> arXiv
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232. <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full> Project Euclid
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR 2016*, 770–778. https://www.cv-foundation.org/openaccess/content_cvpr_2016/papers/He_Deep_Residual_Learning_CVPR_2016_paper.pdf
- Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., ... Adam, H. (2019). Searching for MobileNetV3. *arXiv:1905.02244*. <https://arxiv.org/abs/1905.02244> arXiv+1
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS 2017*. <https://arxiv.org/abs/1705.07874> arXiv
- scikit-learn. (2025). *HistGradientBoostingRegressor* (documentation). <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *ICML 2019* (PMLR). <https://proceedings.mlr.press/v97/tan19a/tan19a.pdf> Proceedings of Machine
- van der Laan, M. J., Polley, E. C., & Hubbard, A. E. (2007). Super learner. *Statistical Applications in Genetics and Molecular Biology*, 6(1), Article 25. (open teaching/working copies available). <https://biostats.bepress.com/ucbbiostat/paper266/>